Backpack Language Models

John Hewitt, John Thickstun, Christopher D. Manning, Percy Liang

ACL2023 Outstanding Paper

発表者：稲葉 達郎

M1, Audio and Speech Processing Lab, Kyoto University

2023/8/27 第15回最先端 NLP 勉強会

概要

手法

- 各単語をそれぞれ文脈に依存しない複数の Sense ベクトルに変換
- Transformer により文脈に依存した重みを計算
- Sense ベクトルの重み付き和をとる

特徴

- Transformer と同等の性能
- 文脈に依存しない Sense ベクトルを組み込むことで操作性・解釈性が向上

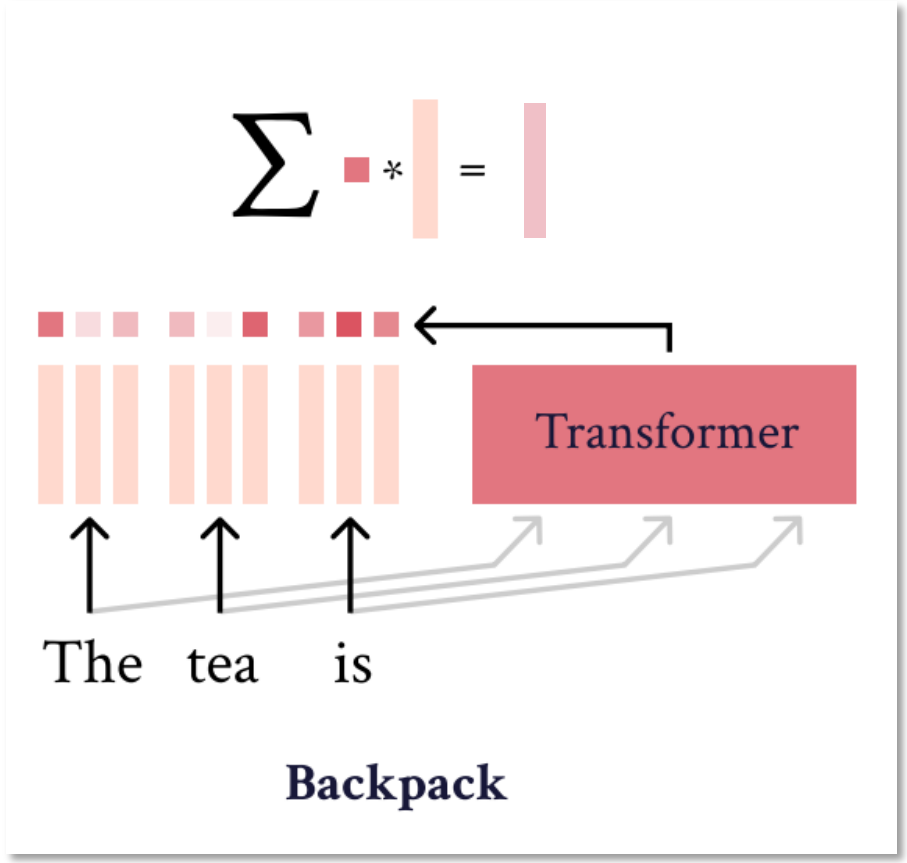

Figure: Backpack Language Models (Hewitt+, ACL2023)

概要

手法

- 各単語をそれぞれ文脈に依存しない複数の Sense ベクトルに変換
- Transformer により文脈に依存した重みを計算
- Sense ベクトルの重み付き和をとる

特徴

- Transformer と同等の性能
- 文脈に依存しない Sense ベクトルを組み込むことで操作性・解釈性が向上

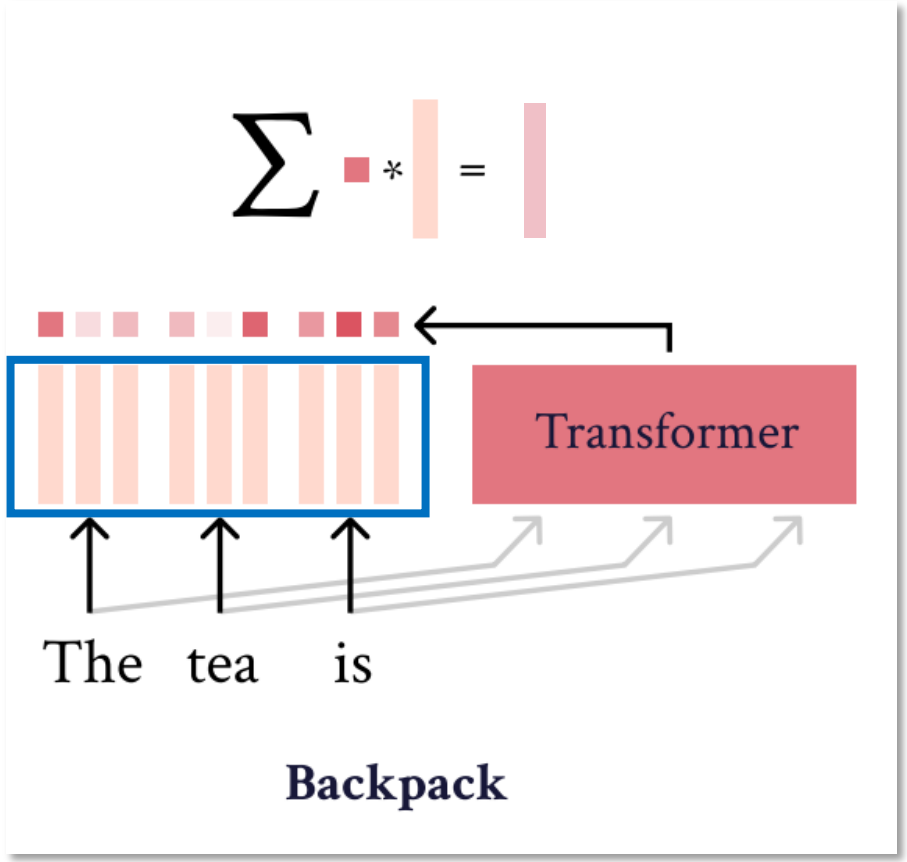

Figure: Backpack Language Models (Hewitt+, ACL2023)

概要

手法

- 各単語をそれぞれ文脈に依存しない複数の Sense ベクトルに変換
- Transformer により文脈に依存した重みを計算
- Sense ベクトルの重み付き和をとる

特徴

- Transformer と同等の性能
- 文脈に依存しない Sense ベクトルを組み込むことで操作性・解釈性が向上

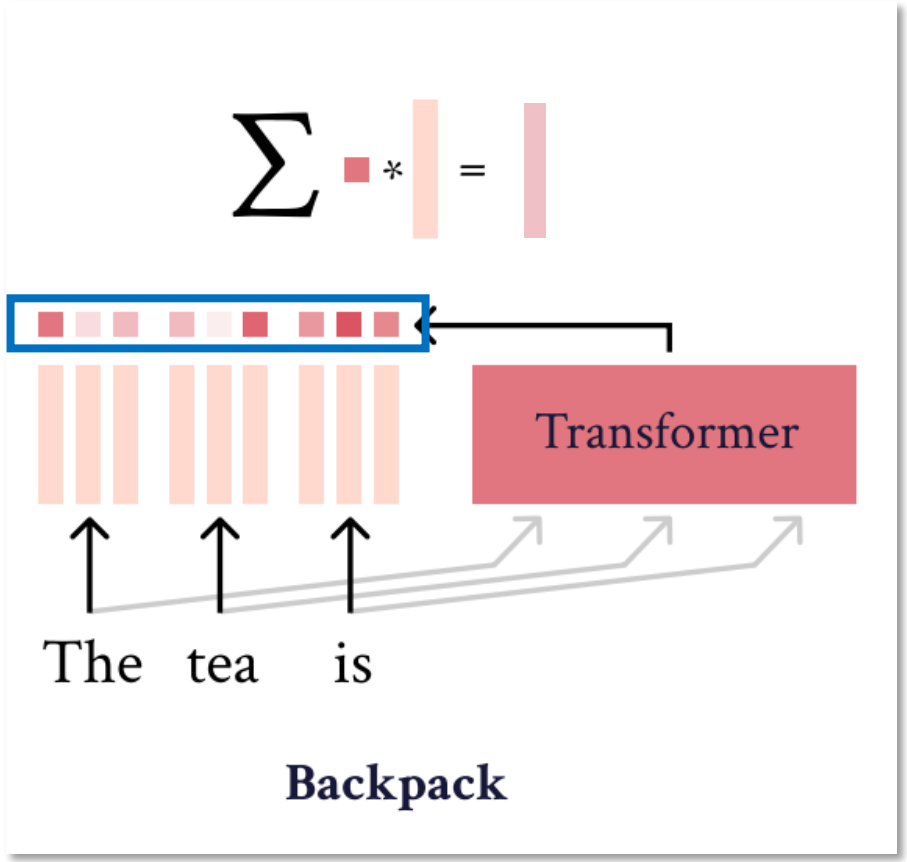

Figure: Backpack Language Models (Hewitt+, ACL2023)

概要

手法

- 各単語をそれぞれ文脈に依存しない複数の Sense ベクトルに変換
- Transformer により文脈に依存した重みを計算
- Sense ベクトルの重み付き和をとる

特徴

- Transformer と同等の性能
- 文脈に依存しない Sense ベクトルを組み込むことで操作性・解釈性が向上

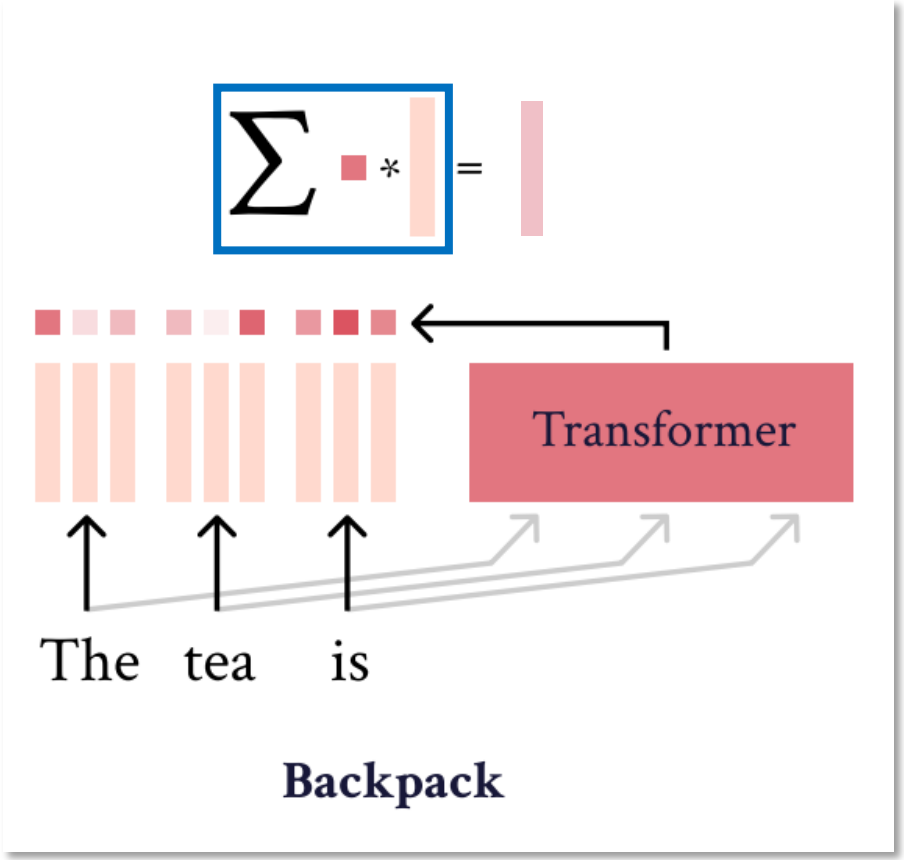

Figure: Backpack Language Models (Hewitt+, ACL2023)

概要

手法

- 各単語をそれぞれ文脈に依存しない複数の Sense ベクトルに変換
- Transformer により文脈に依存した重みを計算
- Sense ベクトルの重み付き和をとる

特徴

- Transformer と同等の性能
- 文脈に依存しない Sense ベクトルを組み込むことで操作性・解釈性が向上

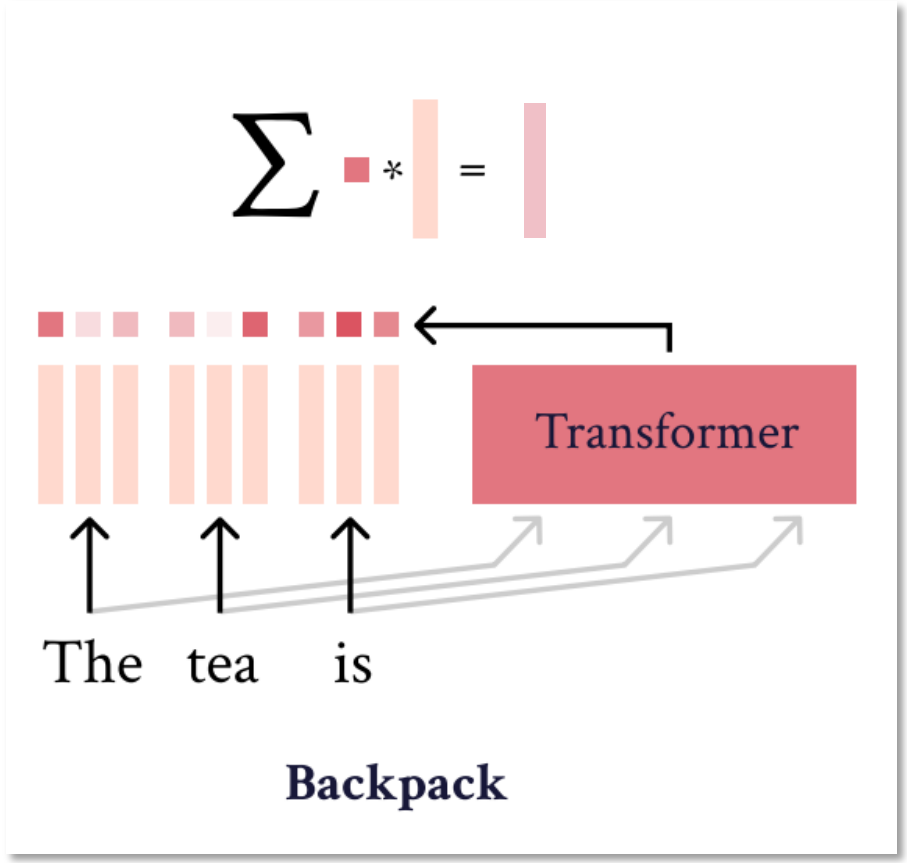

Figure: Backpack Language Models (Hewitt+, ACL2023)

Transformer の操作性・解釈性の低さ

背景：Transformer の操作性・解釈性の低さ

良い点😄

- Attention 層 と MLP 層を繰り返すことで複雑な文脈を考慮した表現を獲得できる
  - 言語モデルはこの表現をもとに，入力文に続く単語を予測

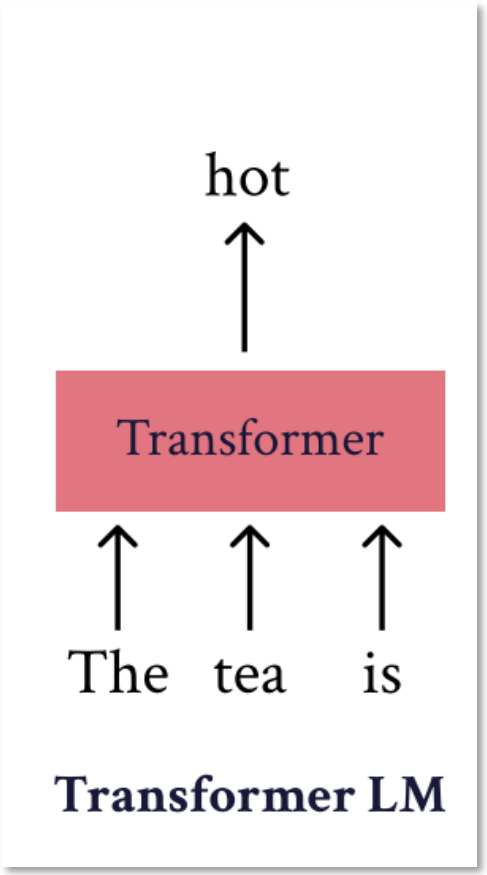

Figure: Backpack Language Models (Hewitt+, ACL2023)

背景：Transformer の操作性・解釈性の低さ

良い点😄

- Attention 層 と MLP 層を繰り返すことで複雑な文脈を考慮した表現を獲得できる
  - 言語モデルはこの表現をもとに，入力文に続く単語を予測

悪い点😇

- 入力から出力まで一通の処理なので，モデル内部へ介入を行うと基本的に非線形な影響が発生
  - 操作・解釈が難しい

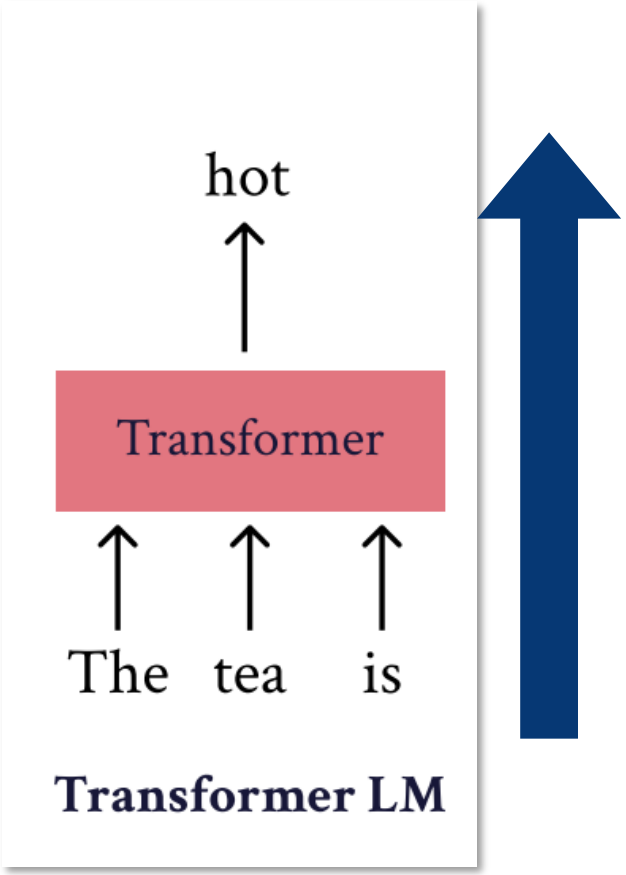

Figure: Backpack Language Models (Hewitt+, ACL2023)

背景：Transformer の操作性・解釈性の低さ

良い点😄

- Attention 層 と MLP 層を繰り返すことで複雑な文脈を考慮した表現を獲得できる
  - 言語モデルはこの表現をもとに，入力文に続く単語を予測

悪い点😇

- 入力から出力まで一通の処理なので，モデル内部へ介入を行うと基本的に非線形な影響が発生
  - 操作・解釈が難しい

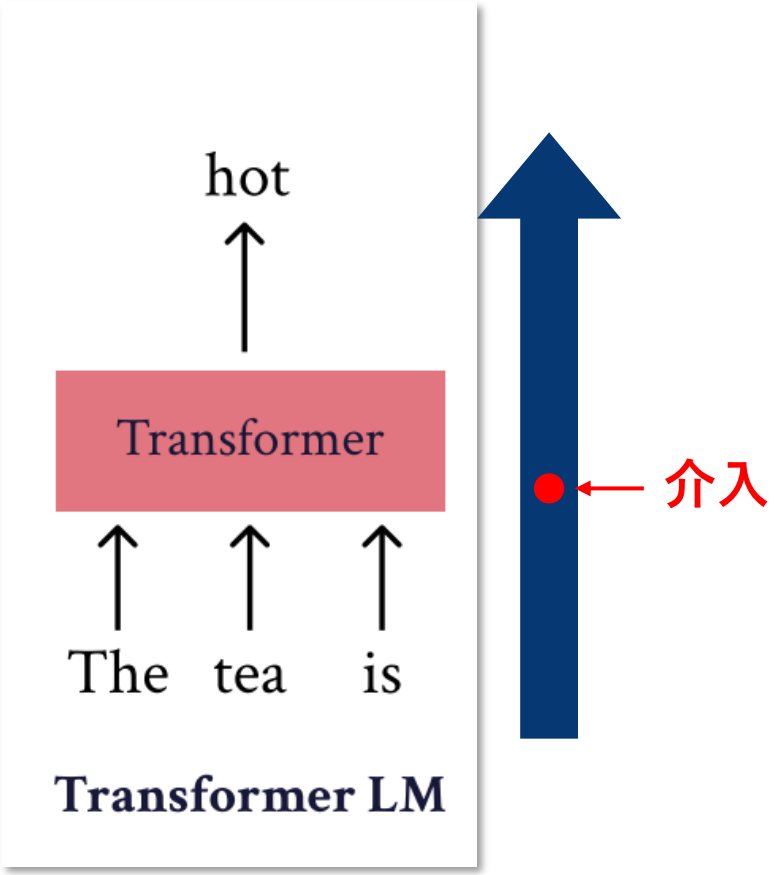

Figure: Backpack Language Models (Hewitt+, ACL2023)

背景：Transformer の操作性・解釈性の低さ

良い点😄

- Attention 層 と MLP 層を繰り返すことで複雑な文脈を考慮した表現を獲得できる
  - 言語モデルはこの表現をもとに，入力文に続く単語を予測

悪い点😇

- 入力から出力まで一通の処理なので，モデル内部へ介入を行うと基本的に非線形な影響が発生
  - 操作・解釈が難しい

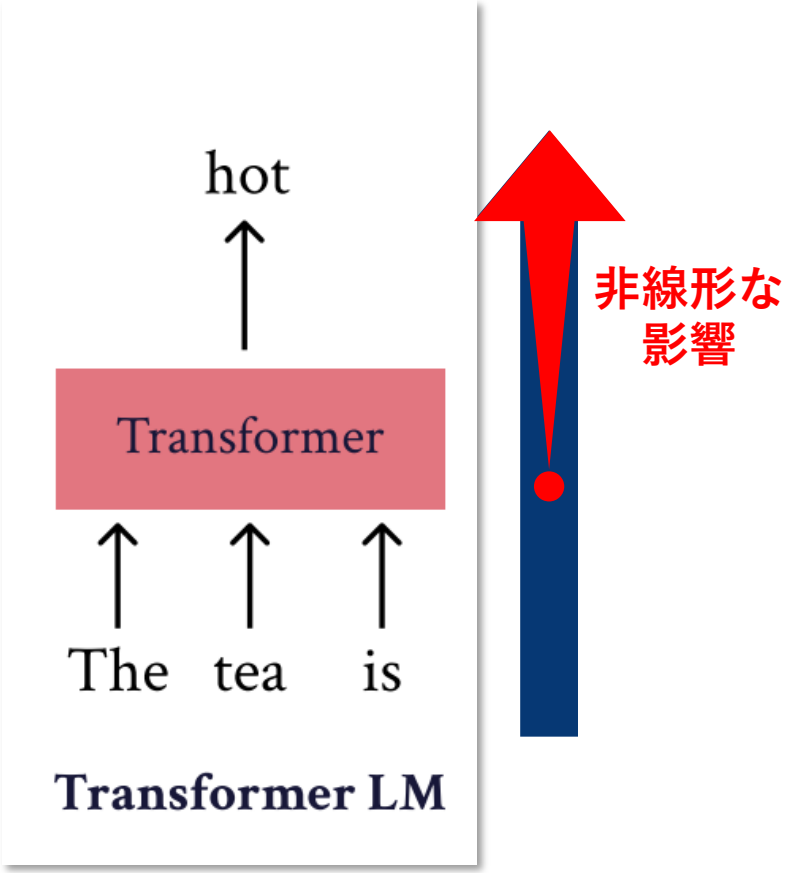

Figure: Backpack Language Models (Hewitt+, ACL2023)

背景：Transformer の操作性・解釈性の低さ

良い点😄

- Attention 層 と MLP 層を繰り返すことで複雑な文脈を考慮した表現を獲得できる
  - 言語モデルはこの表現をもとに，入力文に続く単語を予測

悪い点😇

- 入力から出力まで一通の処理なので，モデル内部へ介入を行うと基本的に非線形な影響が発生
  - 操作・解釈が難しい
  - これを頑張って分析する研究も存在 [Meng+, ICLR2023; Serrano+, ACL2019]

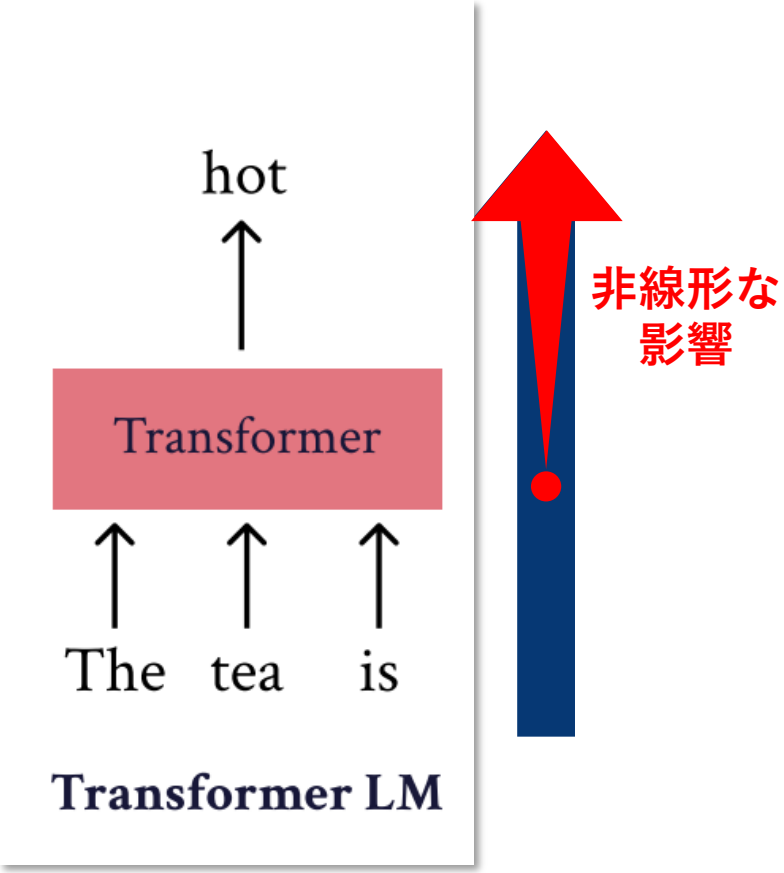

MLP　Attention

Figure: Backpack Language Models (Hewitt+, ACL2023)

Backpack モデルとは？

Backpack: 全体像

- Backpack は文脈を考慮した単語埋め込み表現の獲得方法

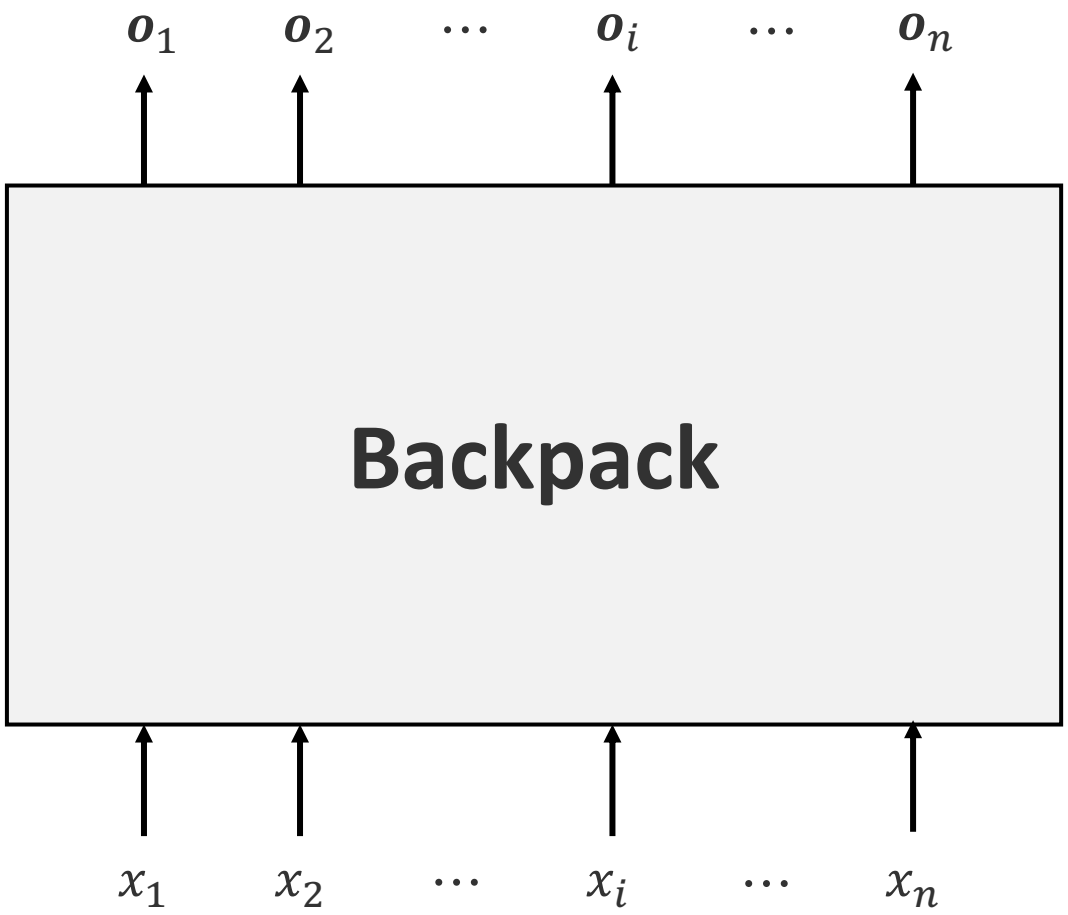

$$\boldsymbol{o}_i = \mathrm{Backpack}(x_1 : x_n)$$

$$(1 \leq i \leq n, x_i \in \mathcal{V}, \boldsymbol{o}_i \in R^d)$$

$\mathcal{V}$ は Vocabulary

Backpack: 全体像

- Backpack は文脈を考慮した単語埋め込み表現の獲得方法

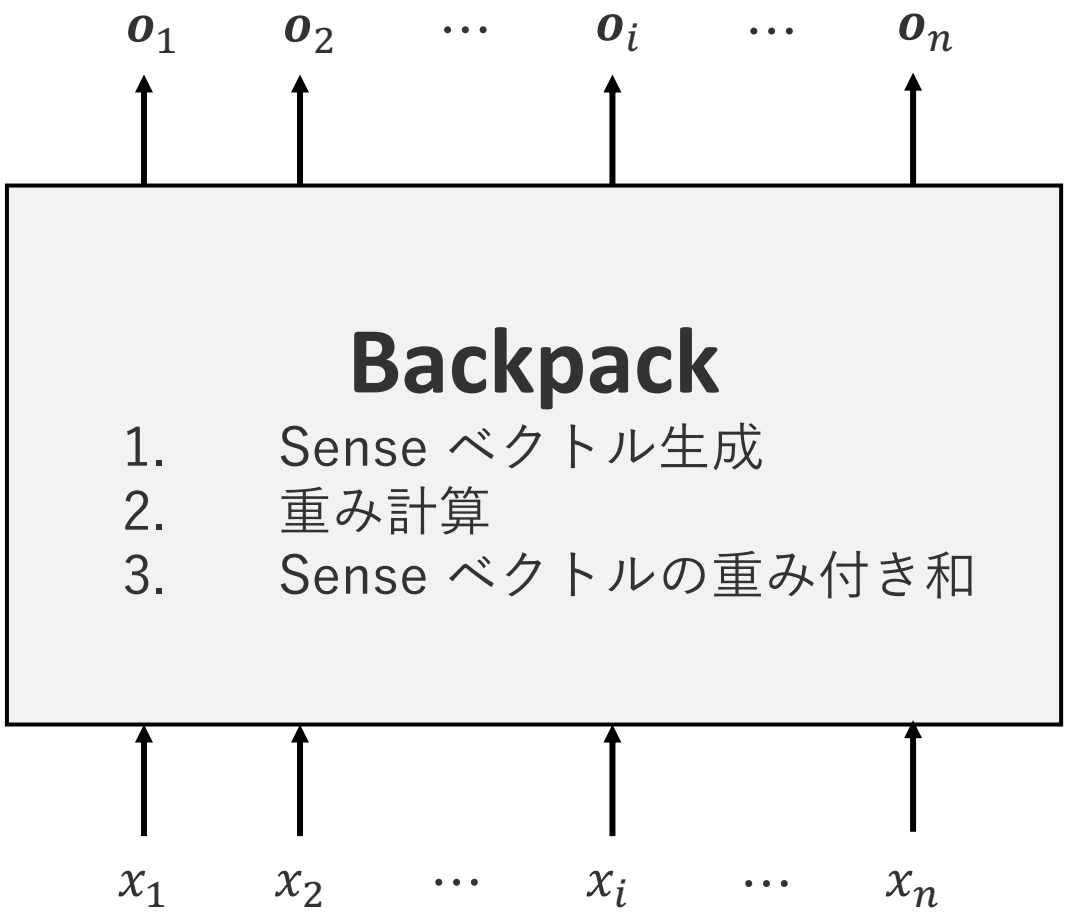

$$\boldsymbol{o}_i = \mathrm{Backpack}(x_1 : x_n)$$

$$(1 \leq i \leq n, x_i \in \mathcal{V}, \boldsymbol{o}_i \in R^d)$$

$\mathcal{V}$ は Vocabulary

Backpack: 単語から Sense ベクトルへ

1. 各単語をそれぞれ文脈に依存しない k(≧1) 個の Sense ベクトルに変換

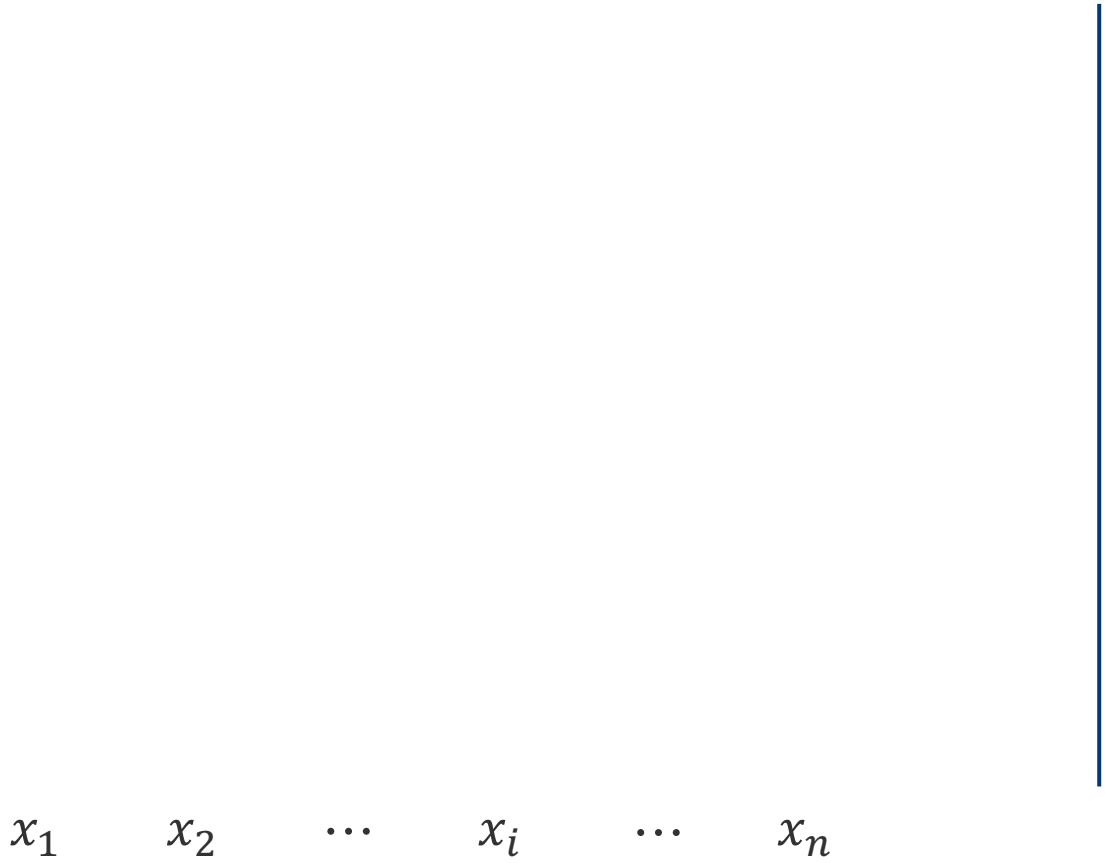

Backpack: 単語から Sense ベクトルへ

1. 各単語をそれぞれ文脈に依存しない k(≧1) 個の Sense ベクトルに変換

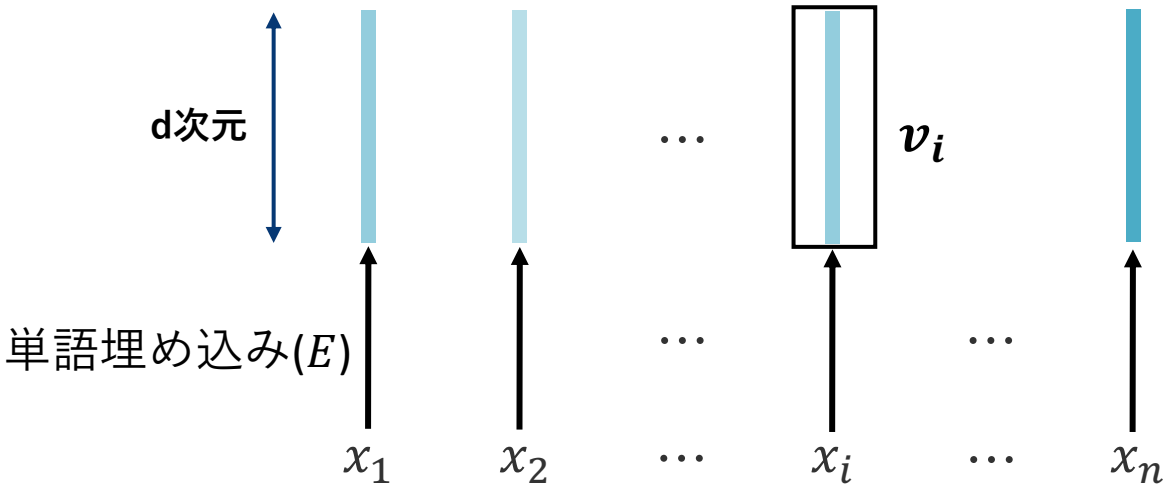

各単語を埋め込み,

$$\boldsymbol{v}_i = E x_i$$

$$\left(\boldsymbol{v}_i \in R^d\right)$$

Backpack: 単語から Sense ベクトルへ

1. 各単語をそれぞれ文脈に依存しない k(≧1) 個の Sense ベクトルに変換

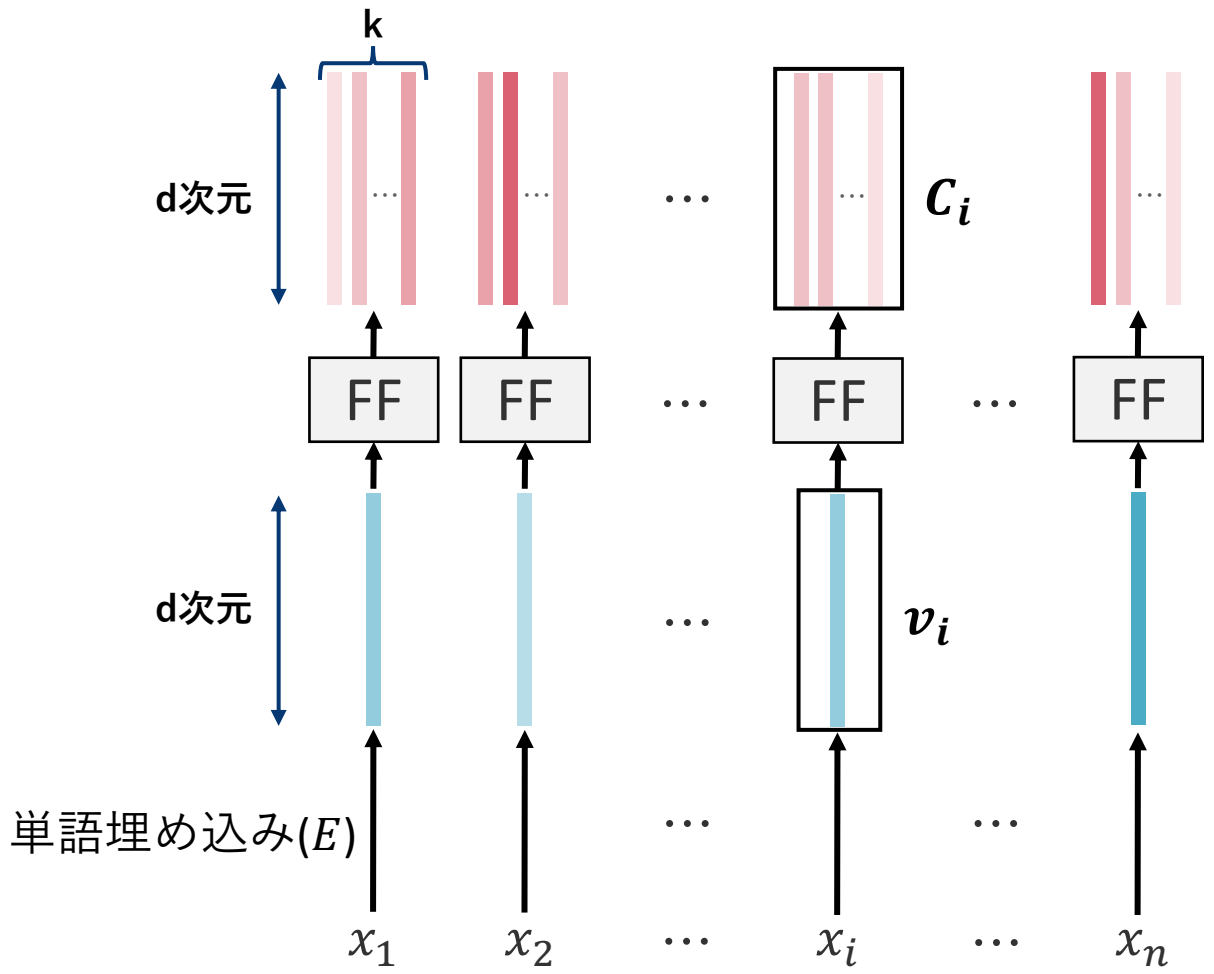

各単語を埋め込み,

$$\boldsymbol{v}_i = E\boldsymbol{x}_i$$

それを Feed-Forward で変換

$$\boldsymbol{C}_i = \mathrm{FF}(\boldsymbol{v}_i)$$

$$\boldsymbol{C} = \{\boldsymbol{C}_1, \ldots, \boldsymbol{C}_i, \ldots, \boldsymbol{C}_n\}$$

$$\begin{pmatrix} \boldsymbol{v}_i \in R^d \\ \boldsymbol{C}_i \in R^{k\times d} \\ \boldsymbol{C} \in R^{n\times k\times d} \end{pmatrix}$$

Backpack: 単語から Sense ベクトルへ

1. 各単語をそれぞれ文脈に依存しない k(≧1) 個の Sense ベクトルに変換

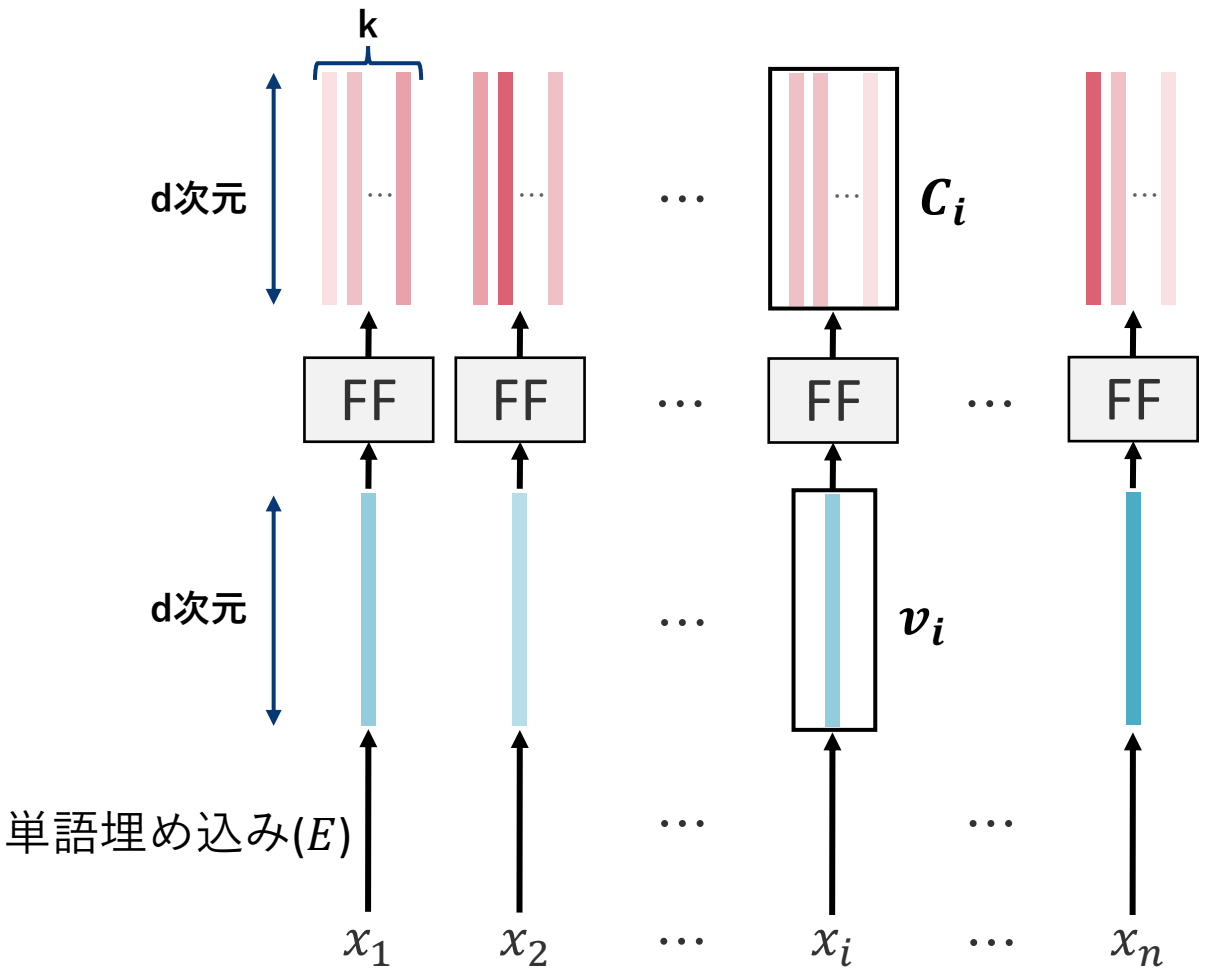

各単語を埋め込み,

$$\boldsymbol{v}_i = E\boldsymbol{x}_i$$

それを Feed-Forward で変換

$$\boldsymbol{C}_i = \mathrm{FF}(\boldsymbol{v}_i)$$

$$\boldsymbol{C} = \{\boldsymbol{C}_1, \ldots, \boldsymbol{C}_i, \ldots, \boldsymbol{C}_n\}$$

$$\begin{pmatrix} \boldsymbol{v}_i \in R^d \\ \boldsymbol{C}_i \in R^{k\times d} \\ \boldsymbol{C} \in R^{n\times k\times d} \end{pmatrix}$$

n 単語 x **k** 個のSense ベクトル x **d** 次元

Backpack: 単語から重みへ

2. Transformer により文脈に依存した重みを計算

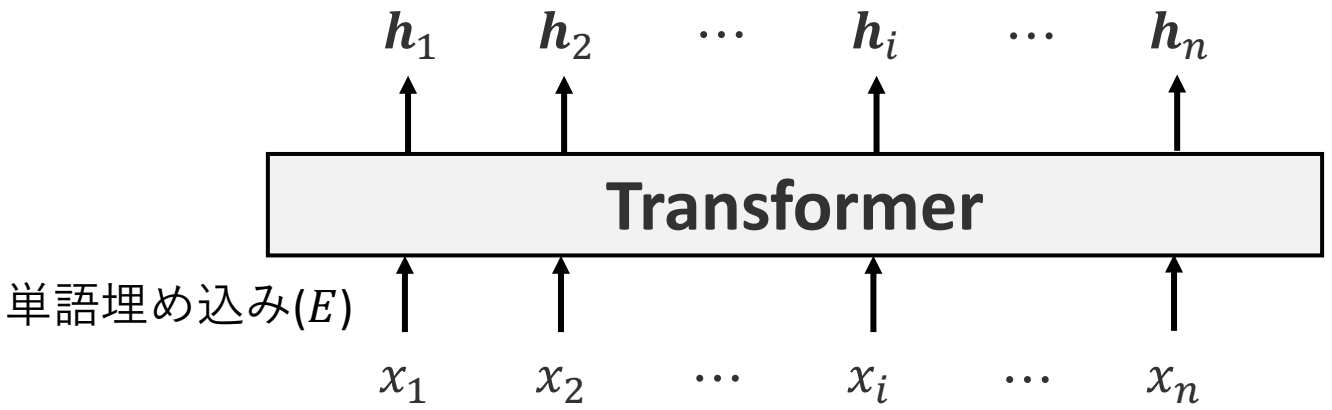

Transformer に文を入力

$$\boldsymbol{h}_{1:n} = \text{transformer}(Ex_{1:n})$$

$$\left(\boldsymbol{h}_{1:n} \in R^{n \times d}\right)$$

Backpack: 単語から重みへ

2. Transformer により文脈に依存した重みを計算

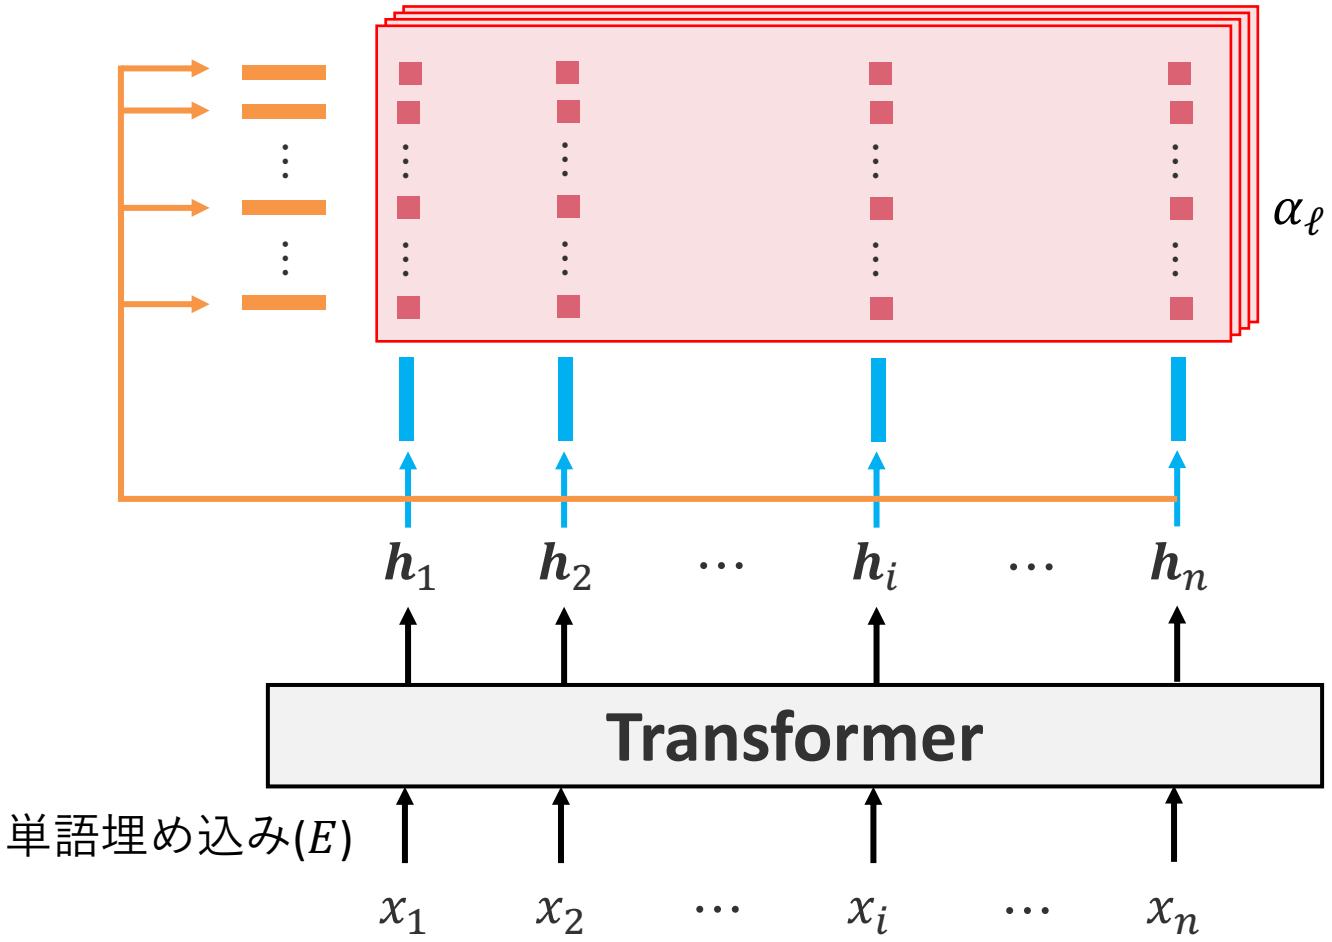

Transformer に文を入力

$$\boldsymbol{h}_{1:n} = \text{transformer}(Ex_{1:n})$$

Head 数 k の Attention map を計算

$$\alpha_\ell = \text{softmax}\left(\boldsymbol{h}_{1:n} W_k^{(\ell)\top} W_Q^{(\ell)} \boldsymbol{h}_{1:n}^\top\right)$$

$$\alpha = \{\alpha_1, \ldots, \alpha_\ell, \ldots, \alpha_k\}$$

$$\begin{pmatrix} \boldsymbol{h}_{1:n} \in R^{n\times d} \\ 1 \le \ell \le k \\ W^{(\ell)}, Q^{(\ell)} \in R^{d\times \frac{d}{k}} \\ \alpha_\ell \in R^{n\times n} \\ \alpha \in R^{k\times n\times n} \end{pmatrix}$$

Backpack: 単語から重みへ

2. Transformer により文脈に依存した重みを計算

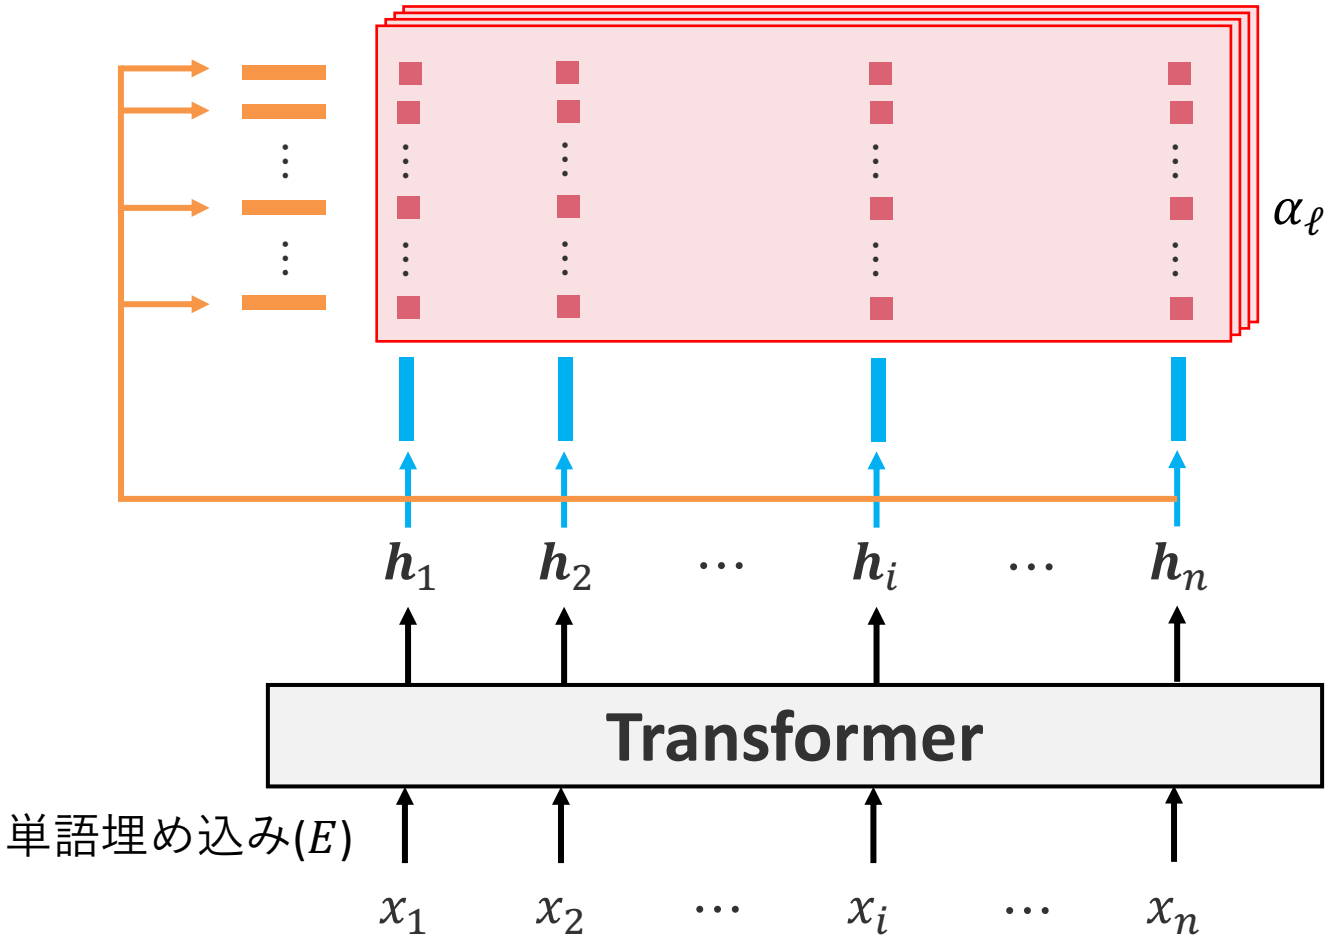

Transformer に文を入力

$$\boldsymbol{h}_{1:n} = \text{transformer}(Ex_{1:n})$$

Head 数 k の Attention map を計算

$$\alpha_\ell = \text{softmax}\left(\boldsymbol{h}_{1:n} W_k^{(\ell)\top} W_Q^{(\ell)} \boldsymbol{h}_{1:n}^\top\right)$$

$$\alpha = \{\alpha_1, \ldots, \alpha_\ell, \ldots, \alpha_k\}$$

$$\begin{pmatrix} \boldsymbol{h}_{1:n} \in R^{n\times d} \\ 1 \le \ell \le k \\ W^{(\ell)}, Q^{(\ell)} \in R^{d\times \frac{d}{k}} \\ \alpha_\ell \in R^{n\times n} \\ \alpha \in R^{k\times n\times n} \end{pmatrix}$$

k 個の Head x **n** 単語 x **n** 単語

Backpack: 重み付き和を計算

3. Sense ベクトルの重み付き和をとる

- 1 から文脈非依存の Sense ベクトル $\boldsymbol{C} \in R^{n \times k \times d}$
- 2 から文脈依存の重み $\alpha \in R^{k \times n \times n}$

これらから，Sense ベクトルの重み付き和を計算

$$\boldsymbol{o}_i = \sum_{j=1}^{n} \sum_{\ell=1}^{k} \alpha_{\ell i j} \boldsymbol{C}_{j,\ell}$$

Backpack: 重み付き和を計算

3. Sense ベクトルの重み付き和をとる

- 1 から文脈非依存の Sense ベクトル $\boldsymbol{C} \in R^{n \times k \times d}$
- 2 から文脈依存の重み $\alpha \in R^{k \times n \times n}$

これらから，Sense ベクトルの重み付き和を計算

$$\boldsymbol{o}_i = \sum_{j=1}^{n} \sum_{\ell=1}^{k} \alpha_{\ell i j} \boldsymbol{C}_{j,\ell}$$

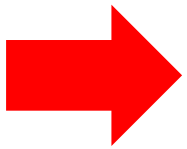

文脈非依存の Sense ベクトルの線形和で
文脈を考慮した単語埋め込み表現を獲得

Backpack Language Models

Backpack Language Models とは?

- Backpack を利用した言語モデル
- 重みを Decoder 型の Transformer で計算

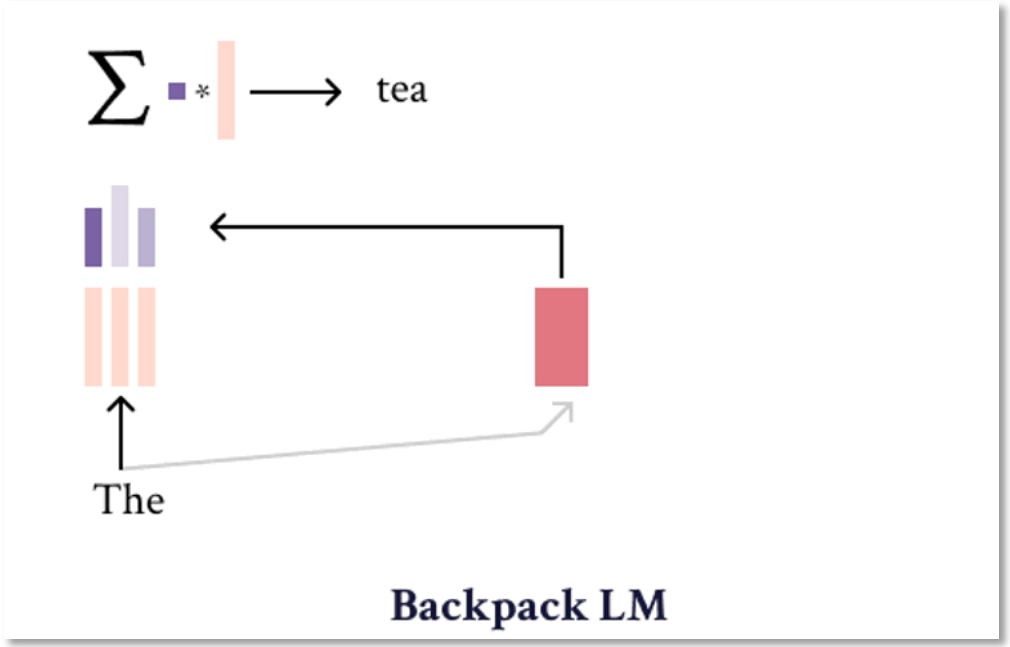

Figure: Backpack Models (Hewitt+, ACL2023)

Backpack Language Models

Backpack Language Models とは?

- Backpack を利用した言語モデル
- 重みを Decoder 型の Transformer で計算

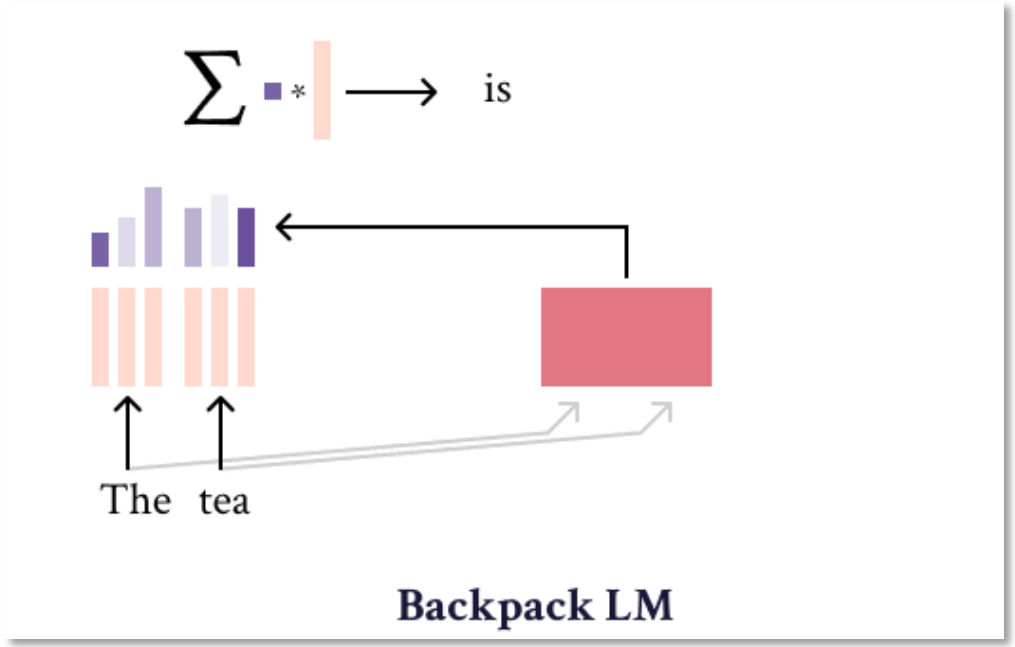

Figure: Backpack Models (Hewitt+, ACL2023)

Backpack Language Models

Backpack Language Models とは?

- Backpack を利用した言語モデル
- 重みを Decoder 型の Transformer で計算

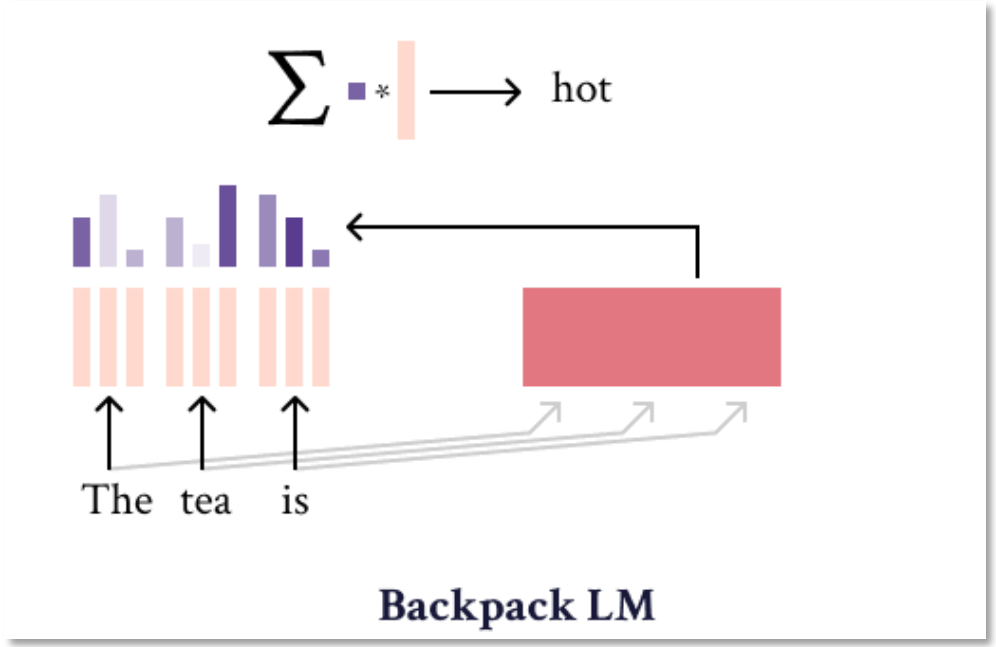

Figure: Backpack Models (Hewitt+, ACL2023)

Backpack Language Models

Backpack Language Models とは?

- Backpack を利用した言語モデル
- 重みを Decoder 型の Transformer で計算

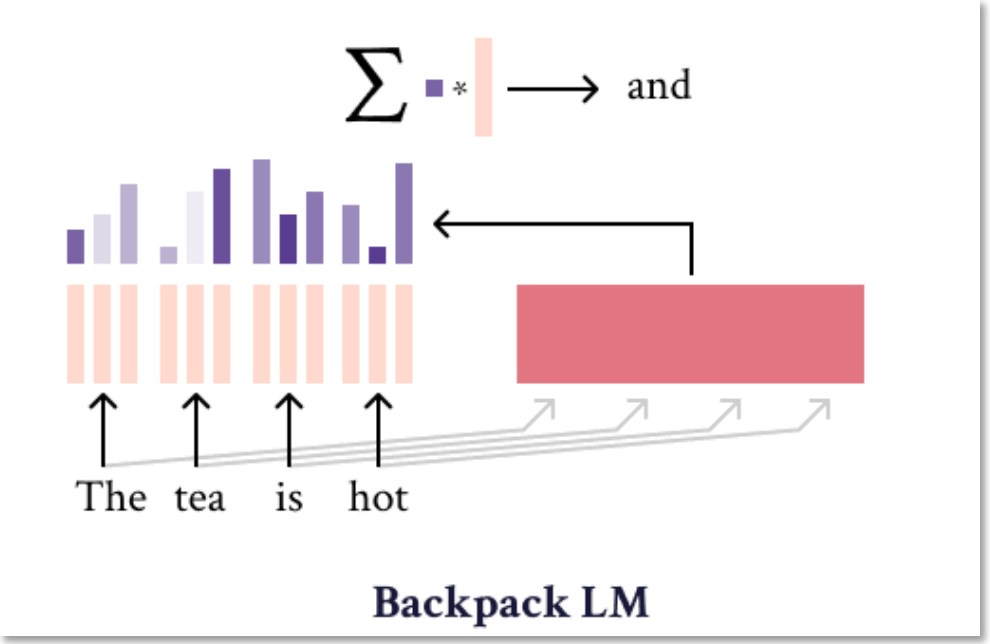

Figure: Backpack Models (Hewitt+, ACL2023)

Backpack Language Models

Backpack Language Models とは?

- Backpack を利用した言語モデル
- 重みを Decoder 型の Transformer で計算

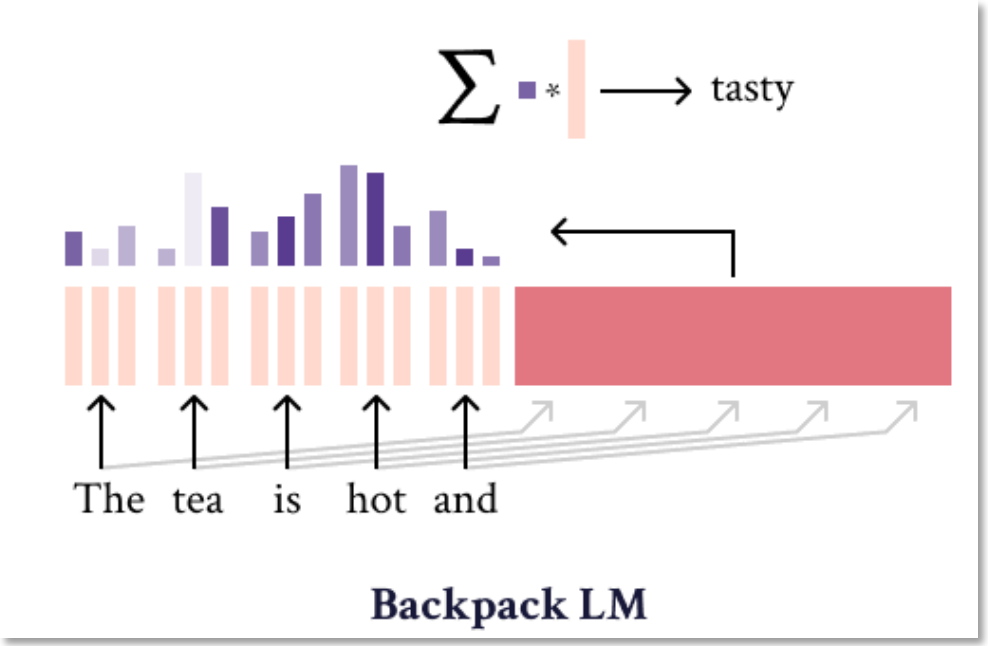

Figure: Backpack Models (Hewitt+, ACL2023)

実験: Backpack Language Models

- モデル
  - Backpack-Micro(40M)/Mini(100M)/Small(170M)
  - Transformer-Micro(30M)/Mini(70M)/Small(124M)
- 学習データ
  - OpenWebtext コーパス [Gokaslan+, 2019]
- 評価
  - Perplexity 等の基本的な評価指標を使用

実験: Backpack Language Models

結果

- どの評価を重視するかにもよるが，Transformer と同等程度の性能を発揮
  - そもそもパラメータ数が同じじゃないのはフェアじゃない感

Model	OpenWebText PPL ↓	LAMBADA PPL ↓	LAMBADA ACC ↑	Wikitext PPL ↓	BLiMP ↑
Backpack-Micro	**31.5**	**110**	**24.7**	**71.5**	75.6
Transformer-Micro	34.4	201	21.3	79.5	**77.8**
Backpack-Mini	**23.5**	**42.7**	**31.6**	**49.0**	76.2
Transformer-Mini	24.5	58.8	29.7	52.8	**80.4**
Backpack-Small	**20.1**	**26.5**	**37.5**	**40.9**	76.3
Transformer-Small	**20.2**	32.7	34.9	42.2	**81.9**

Table: Backpack Language Models (Hewitt+, ACL2023)

Backpack LM の良い点

良い点: 操作性・解釈性が向上

解釈性の例

- ”science” という単語を k = 16 で Sense ベクトル ($\boldsymbol{C}_{science} \in R^{16\times d}$) に変換し，それを $E^{\top}\boldsymbol{C}_{science}$ と投影することで単語の意味（確率分布）を入手可能
  - Sense 7/8 には科学的手法（replicationやexperiments など）
  - Sense 3 は science の後ろに続きやすい単語 (science denial で科学不信)

A few senses of the word *science*

Sense 3	Sense 7	Sense 9	Sense 10	Sense 8
fiction	replication	religion	settled	clones
fictional	citation	rology	sett	experiments
Fiction	Hubble	hydra	settle	mage
literacy	reprodu	religions	unsett	experiment
denial	Discovery	nec	Sett	rats

Table: Backpack Language Models (Hewitt+, ACL2023)

良い点: 操作性・解釈性が向上

操作性の例

- “When the nurse came into the room,” に Backpack LM を適用
- “nurse” という単語の影響で “She” が来る可能性が高い

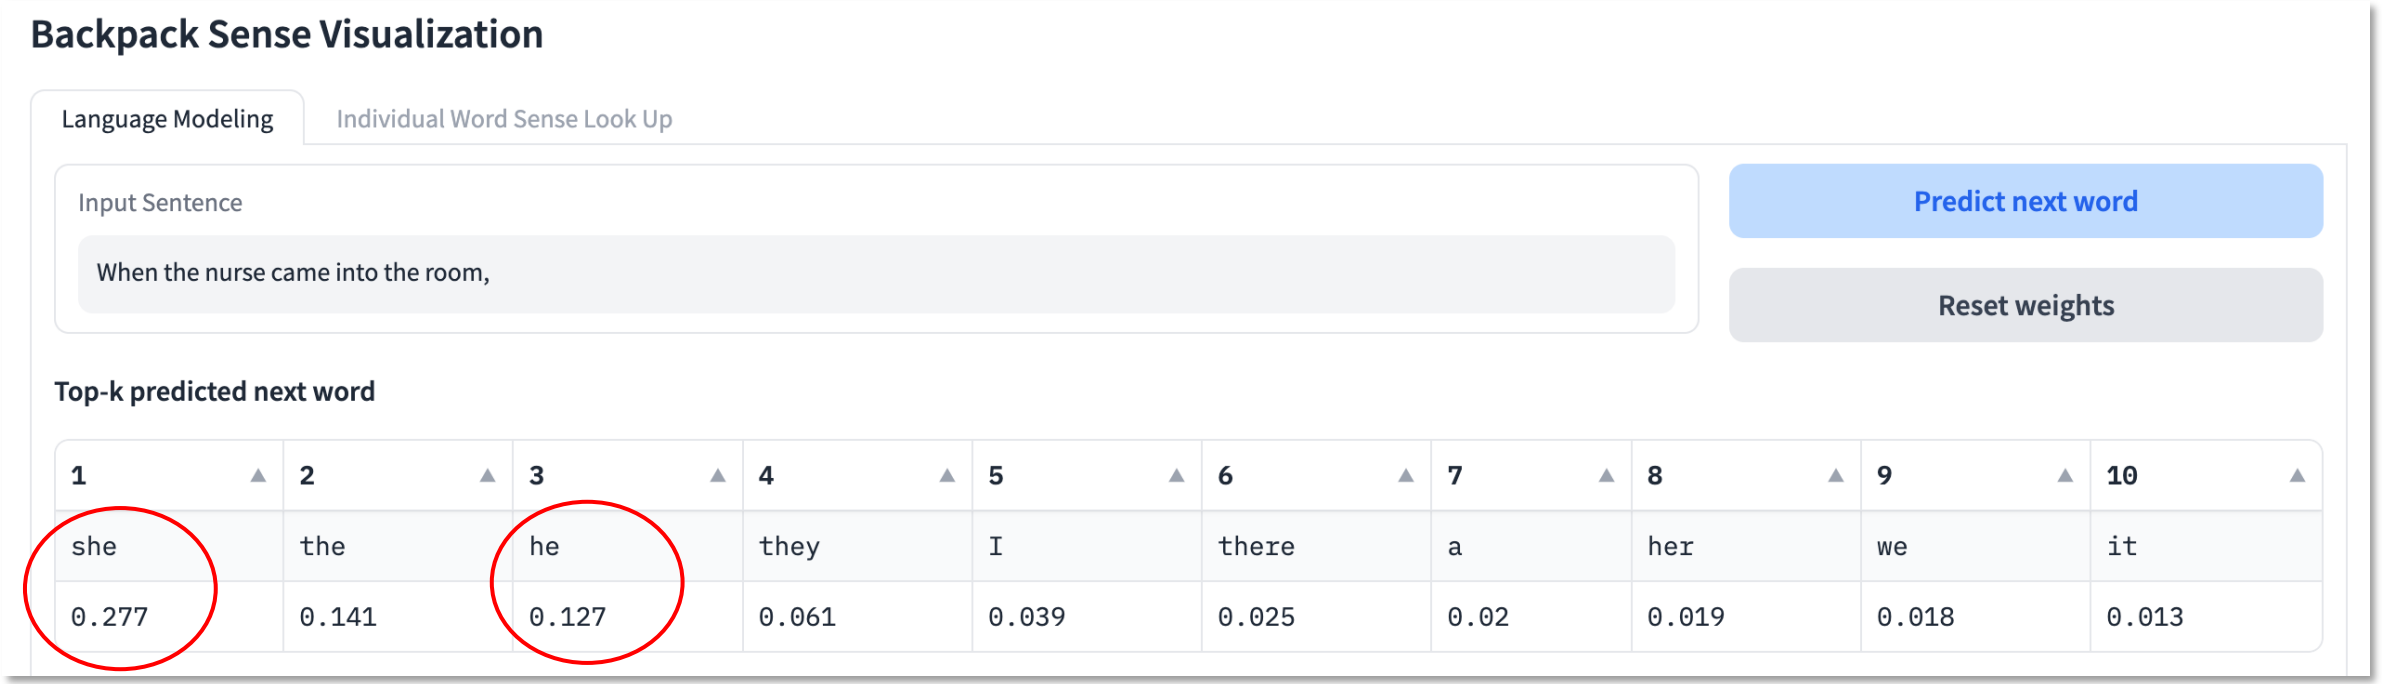

Screenshot: Backpack Demo [at Huggingface]

良い点: 操作性・解釈性が向上

操作性の例

- “nurse” の Sense ベクトルの意味を見てみると，Sense 10 に “She” という意味があった

- この重みを人為的に 0 にしてもう一度次の単語を予測すると．．．

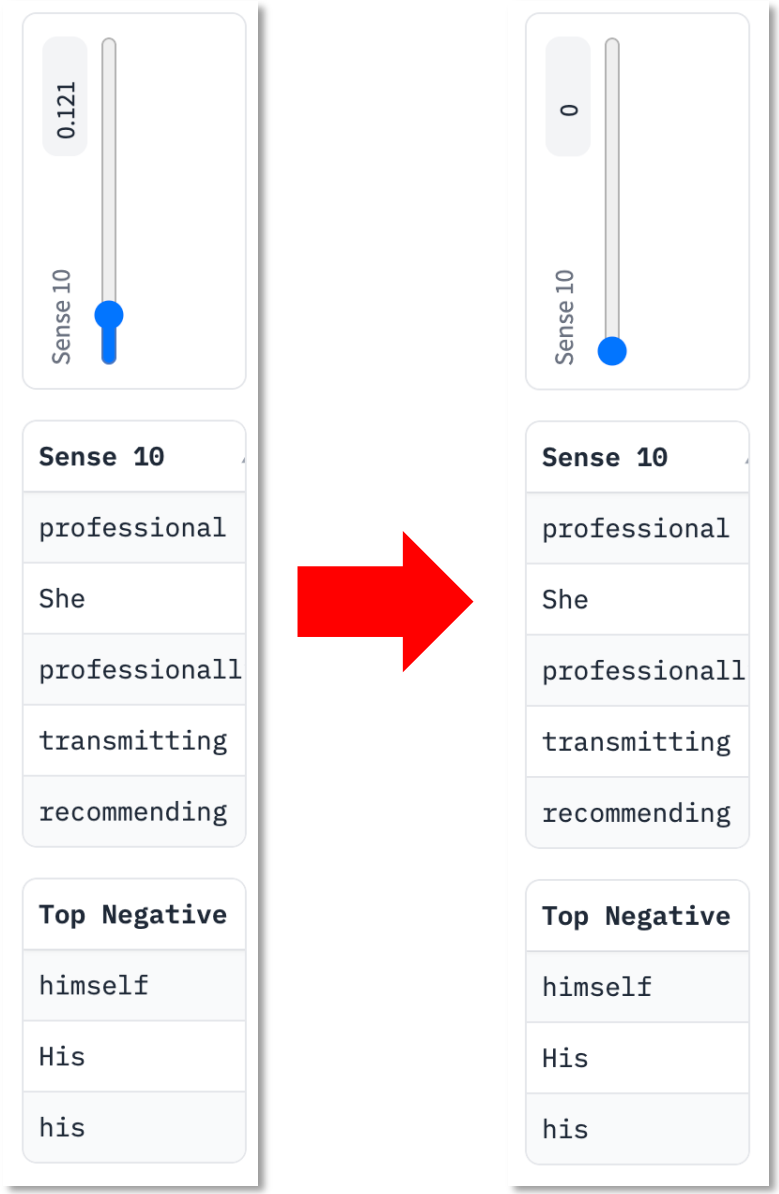

Screenshot: Backpack Demo [at Huggingface]

良い点: 操作性・解釈性が向上

操作性の例

- “She” の確率が低下 (0.277→0.228)し，“He” の確率が増加 (0.127→0.167)

Screenshot: Backpack Demo [at Huggingface]

Backpack LM の注意点

注意点1: 完全に解釈可能になったわけではない

- 全ての Sense ベクトルが綺麗に言語化できるわけではない
  - Sense ベクトルが綺麗に言語化されるような学習は行なっていない
  - “nurse” の Sense ベクトル0~7の意味をみるとあまり一般的でない意味も多い

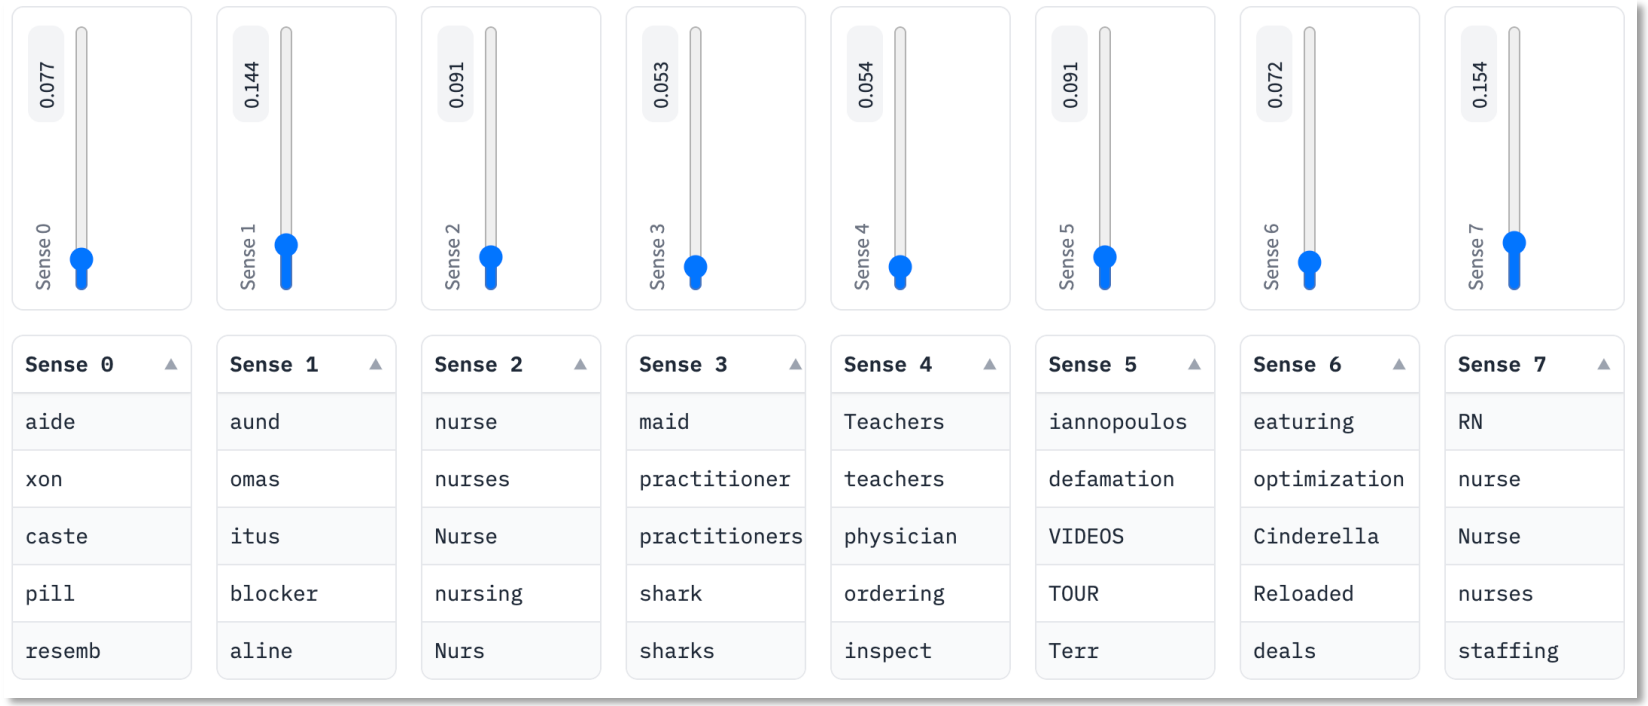

Sense 0	Sense 1	Sense 2	Sense 3	Sense 4	Sense 5	Sense 6	Sense 7
aide	aund	nurse	maid	Teachers	iannopoulos	eaturing	RN
xon	omas	nurses	practitioner	teachers	defamation	optimization	nurse
caste	itus	Nurse	practitioners	physician	VIDEOS	Cinderella	Nurse
pill	blocker	nursing	shark	ordering	TOUR	Reloaded	nurses
resemb	aline	Nurs	sharks	inspect	Terr	deals	staffing

Screenshot: Backpack Demo [at Huggingface]

注意点2: パラメータ数が増加している

- Sense ベクトルを生成するネットワーク分のパラメータが増加している
  - 例：Transformer-small(124M)→Backpack-small(170M)
- Trainable なパラメータが増えたことにより，ロスの収束に時間がかかる
- 性能が同じだと仮定すると，解釈性と計算コストにトレードオフの関係

注意点3: 表現力が下がる可能性

そもそも

- 文脈に依存しない Sense ベクトルの線形和を使用し，重みはかならず正となる

なので

- 否定的な表現が苦手な可能性
  - 「Sense ベクトルの中にネガティブな意味も含まれていて，その重みが大きくなるはず」と論文では述べているが，ポジティブな Sense ベクトルの方が多いはずであり，それらの重みが0になることはない
- 複数の単語が組み合わさって初めて生まれる意味に弱い可能性
  - これも Sense ベクトルの中にそういう意味を持つものがあり，その重みが大きくなるのかもしれないが，出現頻度が低い組み合わせだと，k を大きくしないと対応できない感

まとめ

まとめ

手法

- 各単語をそれぞれ文脈に依存しない複数の Sense ベクトルに変換
- Transformer により文脈に依存した重みを計算
- Sense ベクトルの重み付き和をとる

特徴

- Transformer と同等の性能
- 文脈に依存しない Sense ベクトルを組み込むことで操作性・解釈性が向上

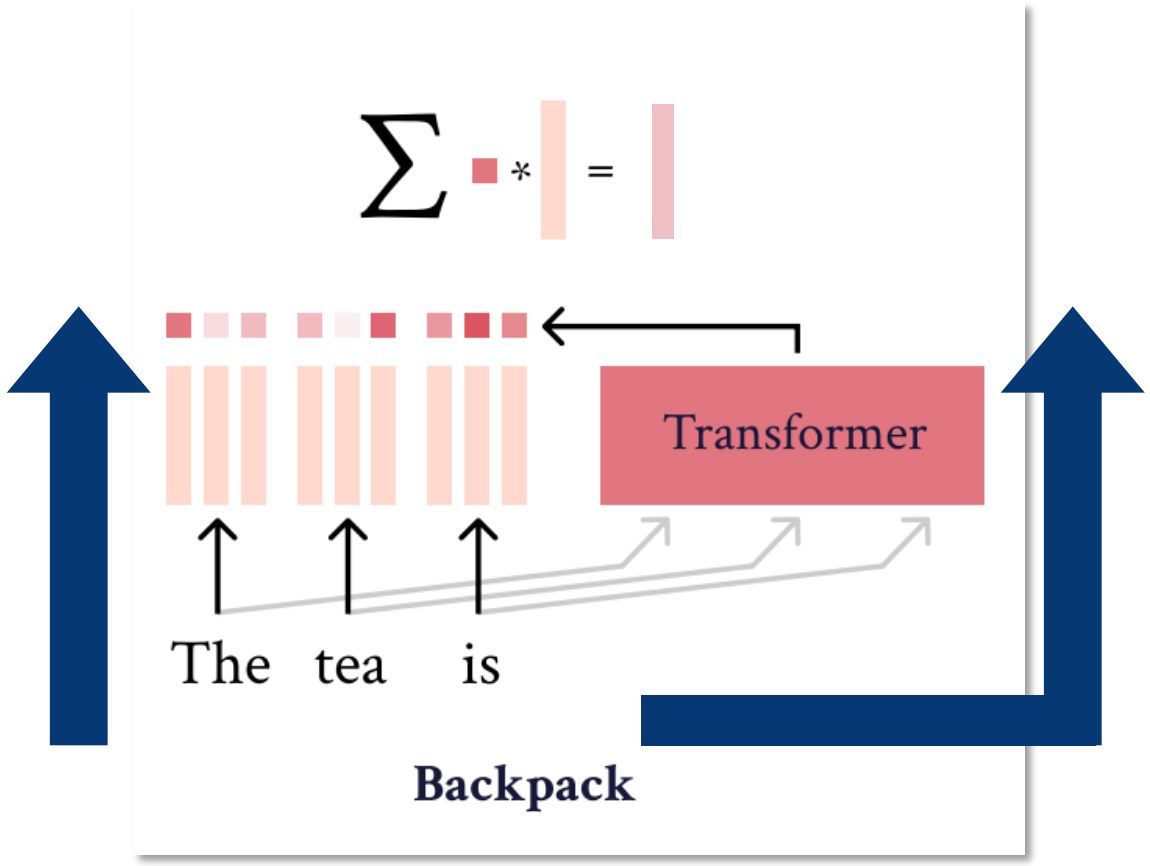

Figure: Backpack Language Models (Hewitt+, ACL2023)